UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO I – TECNOLOGIA EM BANCO DADOS

ANÁLISE DE IMPACTO SOCIAL E INCLUSÃO FINANCEIRA: ESTUDO DE CASO NUBANK

Nome da Empresa: Nubank

Número do Grupo: 2A 6

Integrantes: Marcos Costa Lima Araujo – RA: 10746213

Link do GitHub: https://github.com/marcosaraujoCL/projeto-aplicado-inclusao-financeira

SÃO PAULO – SP

2026

Sumário

1. Objetivo do Estudo 6

1.1. Objetivo Geral 6

1.2. Objetivos Específicos 6

2. Apresentação da Empresa Nubank 7

2.1. Missão, Visão e Valores 7

2.2. Segmento de Atuação 7

2.3. Posicionamento no Mercado 8

2.4. Número de Colaboradores 8

2.5. Iniciativas em Data Science 8

2.6. Trabalhos em Destaque 9

3. Problema do Estudo 9

3.1. Definição do Problema e Questões de Pesquisa 9

3.2. Abordagem pelo Pensamento Computacional 10

4. Apresentação dos Dados (Metadados) 10

4.1. Registro do Dataset 10

4.2. Dicionário de Dados 11

5. Análise Exploratória de Dados (AED) 11

5.1. Visão Geral e Estatística Descritiva 12

5.2. Distribuição de Frequência (Valor de Empréstimo) 13

5.3. Análise de Correlações (Pearson) 14

5.4. Identificação de Anomalias e Outliers 17

Glossário

- **AED (Análise Exploratória de Dados):** Método de análise de conjuntos de dados para resumir suas características principais, frequentemente com recursos visuais.
- **Coeficiente de Correlação de Pearson:** Medida estatística (entre -1 e 1) que indica a força da relação linear entre duas variáveis, como Renda e Juros.
- **Dataset:** Conjunto de dados estruturado, no caso deste projeto, o arquivo credit_risk_dataset.csv com 32.581 registros.
- **Fintech:** Empresa de tecnologia que oferece serviços financeiros de forma digital, exemplificada pelo Nubank neste estudo.
- **LGPD:** Lei Geral de Proteção de Dados, que regula o tratamento de informações pessoais para garantir a privacidade.
- **Metadados:** Informações que descrevem as propriedades técnicas de um Dataset, como tipo de arquivo, origem e descrição dos atributos.
- **ODS 10:** Objetivo de Desenvolvimento Sustentável da ONU focado na Redução das Desigualdades, tema central deste projeto aplicado.
- **Outliers:** Valores atípicos ou anomalias encontradas nos dados, como a idade de 144 anos detectada na variável person_age.

Lista de Figuras

Figura 1 – Sumário estatístico das variáveis numéricas 12

Figura 2 – Histograma da distribuição do valor de empréstimo 13

Figura 3 – Cálculo da correlação de Pearson: Renda vs Juros 14

Figura 4 – Gráfico de tendência: Renda vs. Juros 15

Figura 5 – Cálculo da correlação de Pearson: Histórico vs. Juros 16

Figura 6 – Gráfico de tendência: Histórico vs. Juros 16

Lista de Tabelas

Tabela 1 – Dicionário de Dados e Metadados dos Atributos 11

1. Objetivo do Estudo

1.1. Objetivo Geral

O principal objetivo deste projeto é aproveitar as ferramentas da Ciência de Dados para examinar a situação da inclusão financeira no Brasil, com o Nubank como nosso estudo de caso. Queremos entender de que maneira modelos analíticos podem ajudar a democratizar o acesso ao crédito para grupos que historicamente foram excluídos, contribuindo assim para o cumprimento do ODS 10 (Redução das Desigualdades da ONU).

1.2. Objetivos Específicos

Foram definidos os seguintes passos técnicos para esta etapa do projeto:

- **Contextualização Institucional:** Realizar uma análise do Nubank, identificando sua missão, visão, valores e posicionamento estratégico no mercado de tecnologia financeira.
- **Definição do problema:** definir o problema e perguntas que vão ser respondidas com a análise exploratória do dataset.
- **Registro de Metadados:** Caracterizar o dataset de Risco de Crédito, registrando sua origem, tipo de arquivo, descrição de atributos e conformidade com a LGPD.
- **Aplicação de Estatística Descritiva:** Calcular medidas de posição (média, moda, mediana) e dispersão (variância, desvio padrão) para as variáveis socioeconômicas e financeiras do conjunto de dados.
- **Identificação de Anomalias:** Detectar e analisar outliers (como inconsistências de idade) e valores perdidos que possam impactar a precisão dos modelos preditivos.
- **Fundamentação Computacional:** Aplicar os pilares da decomposição, reconhecimento de padrões e abstração para estruturar uma solução analítica viável ao problema de pesquisa.

2. Apresentação da Empresa Nubank

2.1. Missão, Visão e Valores

O Nubank tem como missão combater a complexidade e empoderar seus clientes, simplificando sua vida financeira com experiências justas e transparentes.

Sua visão é revolucionar o segmento financeiro na América Latina, tornando-se a instituição mais focada no cliente e inovadora do mundo, eliminando a burocracia.

Os valores do Nubank são compostos por cinco pilares, conhecidos como "Nu-values". São eles:

- **Queremos que nossos clientes nos amem fanaticamente:** Foco total no cliente.
- **Somos ávidos e desafiamos o status quo:** Questionar o sistema tradicional e promover mudanças.
- **Agimos como donos:** Senso de responsabilidade e propriedade.
- **Construímos equipes fortes e diversas:** Valorização de perspectivas diferentes.
- **Buscamos eficiência inteligente:** Soluções pioneiras e produtividade.

2.2. Segmento de Atuação

O Nubank é uma empresa de tecnologia com foco em serviços financeiros (fintech) que atua em diversas frentes no mercado brasileiro e internacional:

- **Cartões de Crédito:** Seu produto principal e porta de entrada para milhões de clientes.
- **Conta Digital:** Serviços de conta corrente e pagamentos.
- **Investimentos:** Plataforma de corretagem e fundos.
- **Seguros:** Proteção de vida, celular e automóveis.
- **Marketplace:** Shopping dentro do aplicativo.

Embora a empresa possua um ecossistema variado, este projeto focará especificamente no segmento de Empréstimos Pessoais e Concessão de Crédito.

Justificativa: A escolha desse recorte se deve à necessidade de entender como os modelos de Ciência de Dados do Nubank avaliam perfis de risco, com o objetivo de democratizar o acesso ao capital. É nesse contexto que o impacto da Inclusão Financeira (ODS 10) se torna mais claro, já que uma análise preditiva bem-feita permite que pessoas sem um histórico bancário tradicional tenham a chance de obter seu primeiro crédito.

2.3. Posicionamento no Mercado

O Nubank se firmou como a maior instituição financeira privada do Brasil em números de clientes. Em janeiro de 2026, a empresa anunciou que havia ultrapassado a marca de 112 milhões de clientes no país, o que equivale a cerca de 61% da população adulta brasileira. No final de 2025, o total global atingiu 131 milhões de clientes, contando Brasil, México e Colômbia. Além disso, a companhia foi reconhecida entre as instituições com a menor taxa de reclamação no ranking do Banco Central.

2.4. Número de Colaboradores

Para acompanhar seu crescimento, o Nubank revelou que o número de colaboradores aumentou em 26% entre setembro de 2023 e setembro de 2025, totalizando cerca de 9.500 funcionários. A empresa também anunciou investimentos para expandir seus escritórios no Brasil, visando apoiar essa nova fase de crescimento.

2.5. Iniciativas em Data Science

O Nubank se posiciona como uma empresa orientada por dados e tecnologia, com atuação forte em Data Science, Machine Learning e Business Analytics. Em seus canais técnicos, a empresa destaca que desenvolve modelos para melhorar a experiência do cliente, usando estatística, inteligência artificial e criatividade para prever comportamentos e apoiar decisões de negócio.

A empresa também publica conteúdos sobre experimentação em larga escala, incluindo o uso de CUPED em testes A/B com milhões de clientes e centenas de métricas, além de pesquisas e aplicações com foundation models e sistemas de IA em tempo real.

2.6. Trabalhos em destaque

Em inclusão financeira, o Nubank afirma ter sido responsável pela inclusão de 28 milhões de pessoas no sistema financeiro e por oferecer o primeiro cartão de crédito para mais de 29 milhões de pessoas. Esses números reforçam o papel da empresa na ampliação do acesso a serviços financeiros na América Latina.

Na área de risco e crédito, a empresa desenvolve modelos proprietários para avaliar clientes com pouco ou nenhum histórico bancário tradicional, apoiando a concessão de crédito de forma mais inclusiva e baseada em dados. Isso aparece também em seus materiais sobre expansão de crédito e uso de tecnologia própria.

3. Problema do Estudo

3.1. Definição do Problema e Questões de Pesquisa

O principal problema deste estudo reside na barreira de acesso ao crédito para perfis que não se enquadram nos critérios rígidos dos bancos tradicionais.

Perguntas que pretendemos responder com a AED:

- Quais variáveis socioeconômicas possuem maior correlação com a restrição ao crédito?
- Existe um padrão de valores para clientes com menor tempo de histórico de crédito?
- Como os valores discrepantes (outliers) e dados ausentes podem distorcer a percepção de risco de um cliente?

3.2. Abordagem pelo Pensamento Computacional

Para estruturar a solução analítica, o problema foi decomposto nos quatro pilares do pensamento computacional:

- **Decomposição:** O problema complexo da "Inclusão Financeira" foi dividido em subproblemas menores: análise do perfil demográfico, avaliação da estabilidade profissional e medição do comprometimento da renda.
- **Reconhecimento de Padrões:** Através da AED, buscaremos identificar comportamentos recorrentes em clientes adimplentes versus inadimplentes para entender o que define um "bom pagador" fora dos padrões convencionais.
- **Abstração:** Focaremos nas variáveis de maior impacto (como `person_income` e `loan_int_rate`), ignorando detalhes subjetivos que não contribuem para a previsão estatística de risco.
- **Algoritmos:** A solução final visa a base para um modelo preditivo que processe os metadados de forma automatizada, gerando uma pontuação de crédito mais justa e alinhada ao ODS 10.

4. Apresentação dos dados (Metadados)

O objetivo desta seção é caracterizar e registrar o conjunto de dados selecionado para garantir a rastreabilidade e a transparência da análise.

4.1. Registro do Dataset

- **Tipo de arquivo**: .csv (Comma Separated Values).
- **Origem dos dados**: Aberta (Plataforma Kaggle - *Credit Risk Dataset*).
- **Sensibilidade**: Baixa. O dataset é composto por perfis anonimizados, sem informações que permitam a identificação direta de indivíduos (como CPF ou nomes), atendendo aos princípios de privacidade.
- **Validade**: Coletado em março de 2026 para fins acadêmicos. Torna-se obsoleto ao final do componente curricular Projeto Aplicado I.
- **Fonte**: Kaggle; dataset disponibilizado publicamente.

- **Restrições de uso**: Uso acadêmico e educacional, respeitando as diretrizes da LGPD quanto ao tratamento de dados estatísticos.
- **Informações adicionais**: O dataset possui 32.581 registros e 12 colunas.

4.2. Dicionário de Dados

Com base na análise técnica realizada via biblioteca Pandas, os atributos foram mapeados conforme a tabela abaixo:

Variável	Descrição Técnica	Tipo de dado
person_age	Idade do solicitante (anos).	int64
person_income	Renda anual informada pelo cliente.	int64
person_home_ownership	Tipo de moradia (Aluguel, Própria, Hipoteca).	object
person_emp_length	Tempo de emprego em anos.	float64
loan_intent	Finalidade do empréstimo (Pessoal, Educação, etc).	object
loan_grade	Nota de risco atribuída ao empréstimo (A-G).	object
loan_amnt	Valor total do empréstimo solicitado.	int64
loan_int_rate	Taxa de juros anual aplicada.	float64
loan_status	Situação (0: Em dia, 1: Inadimplente).	int64
loan_percent_income	Relação entre o valor do empréstimo e a renda.	float64
cb_person_default_on_file	Histórico prévio de inadimplência (Y/N).	object
cb_person_cred_hist_length	Tempo de histórico de crédito (anos).	int64

5. Análise Exploratória de Dados (AED)

O objetivo desta etapa é aplicar a estatística descritiva para sumarizar as características do dataset, identificando padrões de comportamento e garantindo a integridade dos dados para as futuras modelagens de risco de crédito.

5.1. Visão Geral e Estatística Descritiva

Iniciamos a exploração calculando as medidas de posição (tendência central) e dispersão. O conjunto de dados conta com 32.581 registros e 12 colunas.

```
         person_age  person_income  person_emp_length     loan_amnt  \
count  32581.000000   3.258100e+04       31686.000000  32581.000000
mean      27.734600   6.607485e+04           4.789686   9589.371106
std        6.348078   6.198312e+04           4.142630   6322.086646
min       20.000000   4.000000e+03           0.000000    500.000000
25%       23.000000   3.850000e+04           2.000000   5000.000000
50%       26.000000   5.500000e+04           4.000000   8000.000000
75%       30.000000   7.920000e+04           7.000000  12200.000000
max      144.000000   6.000000e+06         123.000000  35000.000000

       loan_int_rate   loan_status  loan_percent_income  \
count   29465.000000  32581.000000         32581.000000
mean       11.011695      0.218164             0.170203
std         3.240459      0.413006             0.106782
min         5.420000      0.000000             0.000000
25%         7.900000      0.000000             0.090000
50%        10.990000      0.000000             0.150000
75%        13.470000      0.000000             0.230000
max        23.220000      1.000000             0.830000

       cb_person_cred_hist_length
count                   32581.000000
mean                        5.804211
std                         4.055001
min                         2.000000
25%                         3.000000
50%                         4.000000
75%                         8.000000
max                        30.000000
```

Figura 1 – Sumário estatístico das variáveis numéricas.

Análise dos Resultados:

- **Perfil Etário:** Na amostra analisada, a média de idade dos solicitantes é de 27,7 anos, com 75% da base tendo até 30 anos, o que reforça o posicionamento do Nubank entre o público jovem.
- **Renda e Crédito:** A renda média anual é de $66.074, enquanto o ticket médio dos empréstimos solicitados é de $9.589.

- **Dispersão:** Observamos um desvio padrão muito elevado na renda ($61.983), indicando uma base heterogênea que abrange desde microempreendedores até perfis de alta renda.

5.2. Distribuição de Frequência (Valor de Empréstimo)

Para entender o volume das operações, analisamos a distribuição da variável loan_amnt.

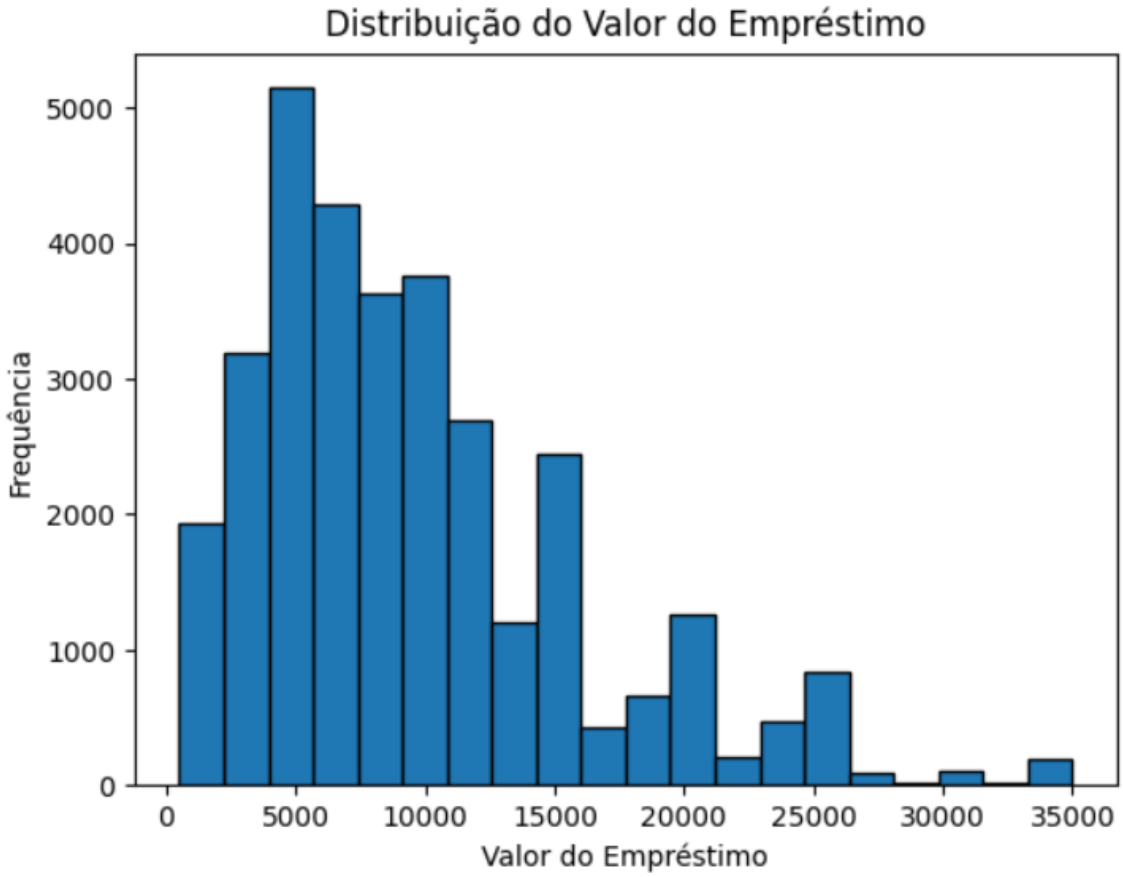

Figura 2 – Histograma da distribuição do valor de empréstimo.

Interpretação:

O histograma revela uma concentração massiva de pedidos na faixa entre $5.000 e $10.000. A frequência cai drasticamente conforme o valor aumenta, o que demonstra o foco da instituição em democratizar o acesso ao crédito através de valores menores e mais pulverizados.

5.3. Análise de Correlações (Pearson)

Testamos a hipótese de que a renda ou o tempo de histórico seriam os únicos determinantes para a taxa de juros. Os resultados desafiam a lógica bancária tradicional.

- **Renda Pessoal vs. Taxa de Juros**

Calculamos o Coeficiente de correlação de Pearson para verificar se quem ganha mais paga menos juros.

```
# --- ANÁLISE DE CORRELAÇÃO: RENDA PESSOAL vs. TAXA DE JUROS ---
#  O coeficiente varia de -1 a 1 e indica a força da relação linear entre Renda e Juros:

# 1. Próximo de -1 (Correlação Negativa Forte):
#  ndica que quanto maior a renda, menores tendem a ser os juros.

# 2. Próximo de 0 (Correlação Linear Fraca ou Ausente):
#  Indica que não há uma relação linear relevante entre as variáveis.
# Nesse caso, a renda isoladamente não influencia significativamente a taxa de juros

# 3. Próximo de 1 (Correlação Positiva Forte):
#  Indica que quanto maior a renda, maiores tendem a ser os juros.

correlacao_renda_pessoal = df['person_income'].corr(df['loan_int_rate'])

print(f"O Coeficiente de Correlação é: {correlacao_renda_pessoal:.4f}")
✓ 0.0s

O Coeficiente de Correlação de Pearson é: 0.0008
```

Figura 3 – Cálculo da correlação de Pearson: Renda vs Juros.

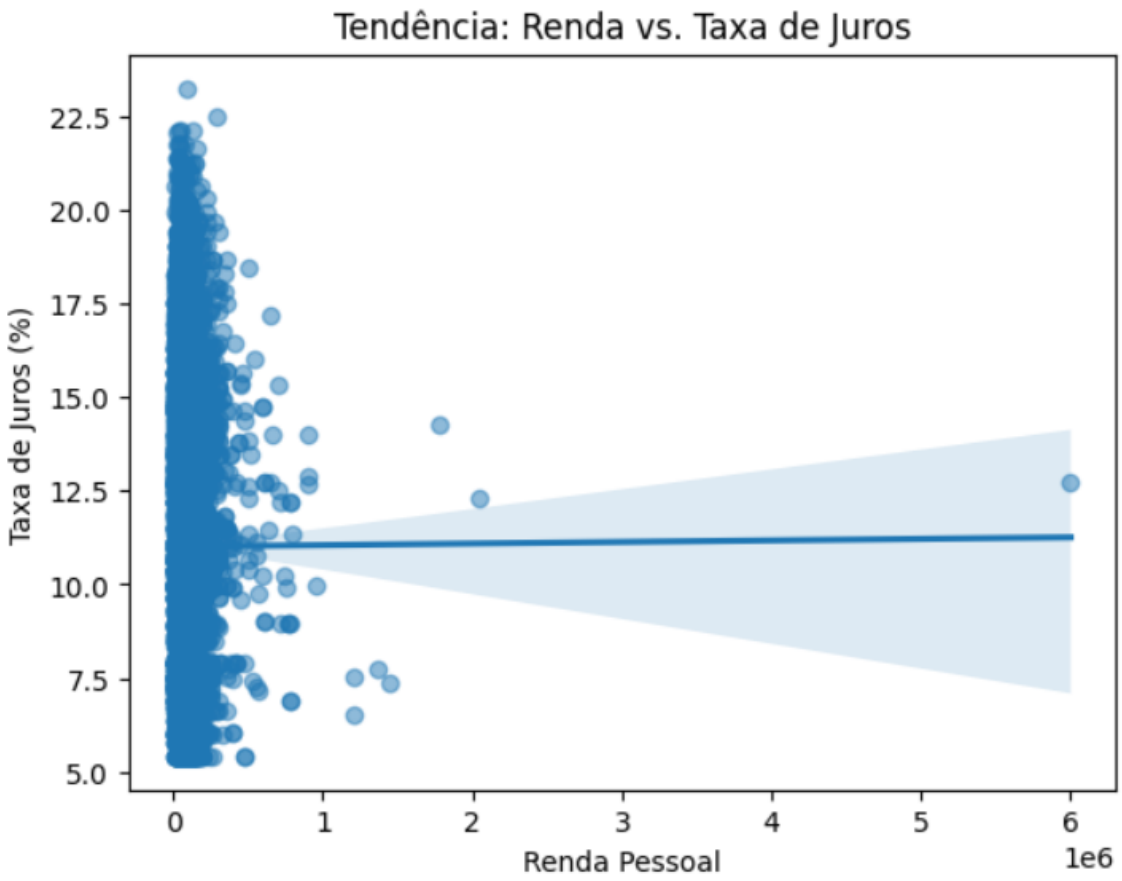

Figura 4 – Gráfico de tendência: Renda vs. Juros.

O valor obtido indica uma ausência de correlação linear. Visualmente, a linha de tendência é horizontal, indicando que a renda pessoal não influencia significativamente na taxa de juros, permitindo que perfis de menor renda também acessem taxas competitivas.

- **Histórico de Crédito vs. Taxa de Juros**

Analisamos se o histórico de crédito no sistema financeiro dita o preço do crédito.

```
# --- ANÁLISE DE CORRELAÇÃO: HISTÓRICO DE CRÉDITO vs. TAXA DE JUROS ---
# O Coeficiente de Pearson avalia a relação linear entre o histórico de crédito e a taxa de juros:

# 1. Próximo de -1:
# Indica que quanto maior o histórico, menor tende a ser a taxa de juros.

# 2. Próximo de 0:
# Indica ausência de relação linear relevante entre as variáveis.
# Nesse caso, o histórico de crédito isoladamente não parece influenciar bem a taxa de juros.

# 3. Próximo de 1:
# Indica que quanto maior o histórico, maior tende a ser a taxa de juros.

# RESULTADO OBTIDO: 0.0167 (Praticamente zero)
# CONCLUSÃO: O tempo de histórico de crédito (cb_person_cred_hist_length) não apresenta
# relação linear relevante com a taxa de juros (loan_int_rate) neste dataset.

correlacao_tempo_credito = df['cb_person_cred_hist_length'].corr(df['loan_int_rate'])

print(f"O Coeficiente de Correlação é: {correlacao_tempo_credito:.4f}")
✓ 0.0s

O Coeficiente de Correlação é: 0.0167
```

Figura 5 – Cálculo da correlação de Pearson: Histórico vs. Juros.

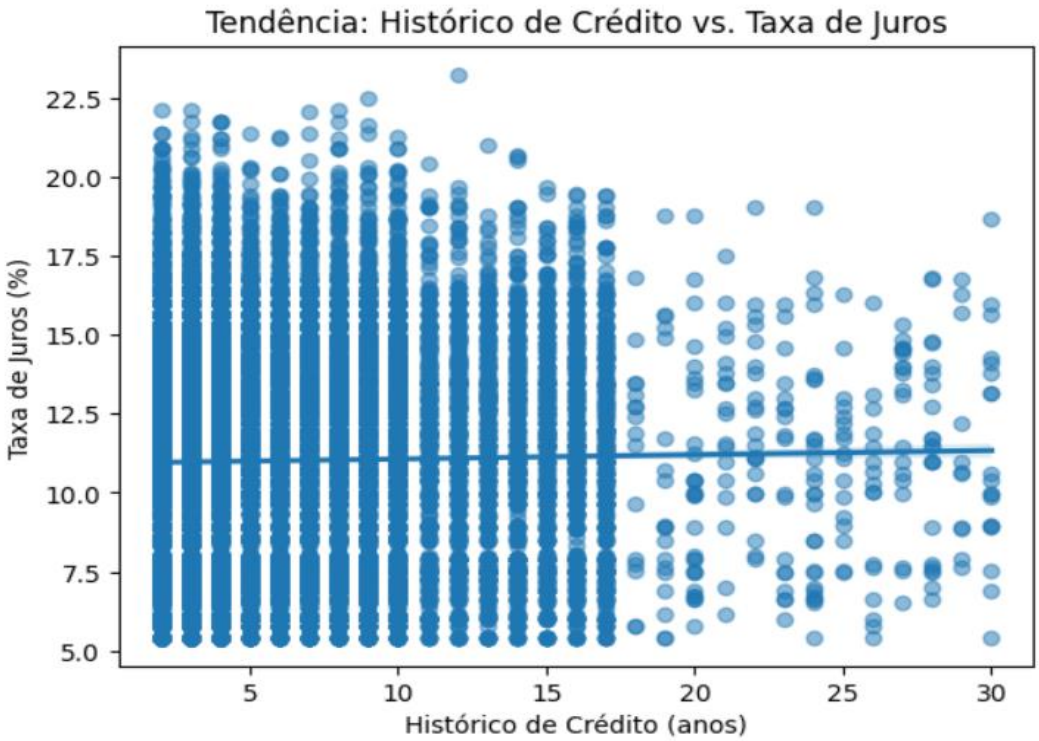

Figura 6 – Gráfico de tendência: Histórico vs. Juros.

O resultado aponta que o histórico de crédito não influencia significativamente na taxa de juros. Isso é um forte indício de Inclusão Financeira (ODS 10), pois a correlação sugere que novos entrantes no mercado não são penalizados com taxas maiores apenas por serem "novos" no sistema.

5.4. Identificação de Anomalias e Outliers

A análise dos dados revelou pontos que precisam de atenção técnica antes de qualquer tomada de decisão:

- **Idade Impossível:** Detectamos um valor máximo de 144 anos na variável person_age.
- **Tempo de Emprego:** Foi registrado um máximo de 123 anos de tempo de serviço.
- **Renda Discrepante:** Um registro de renda de $6 milhões que, embora possível, distorce as médias gerais e atua como um outlier no modelo.