



UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO I – TECNOLOGIA EM BANCO DADOS

ANÁLISE DE IMPACTO SOCIAL E INCLUSÃO FINANCEIRA: ESTUDO DE CASO NUBANK

Nome da Empresa: Nubank

Número do Grupo: 2A 6

Integrantes: Marcos Costa Lima Araujo – RA: 10746213

Link do GitHub: <https://github.com/marcosaraujoCL/projeto-aplicado-inclusao-financeira>

SÃO PAULO – SP

2026



Sumário

1. Objetivo do Estudo	6
1.1. Objetivo Geral	6
1.2. Objetivos Específicos	6
2. Apresentação da Empresa Nubank	7
2.1. Missão, Visão e Valores	7
2.2. Segmento de Atuação	7
2.3. Posicionamento no Mercado	8
2.4. Número de Colaboradores	8
2.5. Iniciativas em Data Science	8
2.6. Trabalhos em Destaque	9
3. Problema do Estudo	9
3.1. Definição do Problema e Questões de Pesquisa	9
3.2. Abordagem pelo Pensamento Computacional	10
4. Apresentação dos Dados (Metadados)	10
4.1. Registro do Dataset	10
4.2. Dicionário de Dados	11
5. Análise Exploratória de Dados (AED)	11
5.1. Visão Geral e Estatística Descritiva	12
5.2. Distribuição de Frequência (Valor de Empréstimo)	13
5.3. Análise de Correlações (Pearson)	14
5.4. Identificação de Anomalias e Outliers	17
6. Esboço do Storytelling para a Gravação do Vídeo Final	18



Glossário

- **AED (Análise Exploratória de Dados):** Método de análise de conjuntos de dados para resumir suas características principais, frequentemente com recursos visuais.
- **Coeficiente de Correlação de Pearson:** Medida estatística (entre -1 e 1) que indica a força da relação linear entre duas variáveis, como Renda e Juros.
- **Dataset:** Conjunto de dados estruturado, no caso deste projeto, o arquivo `credit_risk_dataset.csv` com 32.581 registros.
- **Fintech:** Empresa de tecnologia que oferece serviços financeiros de forma digital, exemplificada pelo Nubank neste estudo.
- **LGPD:** Lei Geral de Proteção de Dados, que regula o tratamento de informações pessoais para garantir a privacidade.
- **Metadados:** Informações que descrevem as propriedades técnicas de um Dataset, como tipo de arquivo, origem e descrição dos atributos.
- **ODS 10:** Objetivo de Desenvolvimento Sustentável da ONU focado na Redução das Desigualdades, tema central deste projeto aplicado.
- **Outliers:** Valores atípicos ou anomalias encontradas nos dados, como a idade de 144 anos detectada na variável `person_age`.
- **Big Data:** Conjunto de técnicas e ferramentas capazes de processar, armazenar e analisar volumes massivos de dados estruturados e não estruturados em alta velocidade.
- **Machine Learning:** Subcampo da inteligência artificial focado no desenvolvimento de algoritmos que aprendem padrões a partir de dados históricos para realizar previsões ou tomar decisões de forma automatizada.
- **Storytelling:** Prática de contar histórias utilizando uma estrutura narrativa bem definida, dividida em setup, conflito e resolução, para transmitir uma mensagem ou apresentar um projeto de forma clara e envolvente.



Lista de Figuras

Figura 1 – Sumário estatístico das variáveis numéricas	12
Figura 2 – Histograma da distribuição do valor de empréstimo	13
Figura 3 – Cálculo da correlação de Pearson: Renda vs Juros	14
Figura 4 – Gráfico de tendência: Renda vs. Juros	15
Figura 5 – Cálculo da correlação de Pearson: Histórico vs. Juros	16
Figura 6 – Gráfico de tendência: Histórico vs. Juros	16



Lista de Tabelas

Tabela 1 – Dicionário de Dados e Metadados dos Atributos	11
--	----



1. Objetivo do Estudo

1.1. Objetivo Geral

O principal objetivo deste projeto é aproveitar as ferramentas da Ciência de Dados para examinar a situação da inclusão financeira no Brasil, com o Nubank como nosso estudo de caso. Queremos entender de que maneira modelos analíticos podem ajudar a democratizar o acesso ao crédito para grupos que historicamente foram excluídos, contribuindo assim para o cumprimento do ODS 10 (Redução das Desigualdades da ONU).

1.2. Objetivos Específicos

Foram definidos os seguintes passos técnicos para esta etapa do projeto:

- **Contextualização Institucional:** Realizar uma análise do Nubank, identificando sua missão, visão, valores e posicionamento estratégico no mercado de tecnologia financeira.
- **Definição do problema:** definir o problema e perguntas que vão ser respondidas com a análise exploratória do dataset.
- **Registro de Metadados:** Caracterizar o dataset de Risco de Crédito, registrando sua origem, tipo de arquivo, descrição de atributos e conformidade com a LGPD.
- **Aplicação de Estatística Descritiva:** Calcular medidas de posição (média, moda, mediana) e dispersão (variância, desvio padrão) para as variáveis socioeconômicas e financeiras do conjunto de dados.
- **Identificação de Anomalias:** Detectar e analisar outliers (como inconsistências de idade) e valores perdidos que possam impactar a precisão dos modelos preditivos.
- **Fundamentação Computacional:** Aplicar os pilares da decomposição, reconhecimento de padrões e abstração para estruturar uma solução analítica viável ao problema de pesquisa.



2. Apresentação da Empresa Nubank

2.1. Missão, Visão e Valores

O Nubank tem como missão combater a complexidade e empoderar seus clientes, simplificando sua vida financeira com experiências justas e transparentes.

Sua visão é revolucionar o segmento financeiro na América Latina, tornando-se a instituição mais focada no cliente e inovadora do mundo, eliminando a burocracia.

Os valores do Nubank são compostos por cinco pilares, conhecidos como "Nu-values". São eles:

- **Queremos que nossos clientes nos amem fanaticamente:** Foco total no cliente.
- **Somos ávidos e desafiamos o status quo:** Questionar o sistema tradicional e promover mudanças.
- **Agimos como donos:** Senso de responsabilidade e propriedade.
- **Construímos equipes fortes e diversas:** Valorização de perspectivas diferentes.
- **Buscamos eficiência inteligente:** Soluções pioneiras e produtividade.

2.2. Segmento de Atuação

O Nubank é uma empresa de tecnologia com foco em serviços financeiros (fintech) que atua em diversas frentes no mercado brasileiro e internacional:

- **Cartões de Crédito:** Seu produto principal e porta de entrada para milhões de clientes.
- **Conta Digital:** Serviços de conta corrente e pagamentos.
- **Investimentos:** Plataforma de corretagem e fundos.
- **Seguros:** Proteção de vida, celular e automóveis.
- **Marketplace:** Shopping dentro do aplicativo.



Embora a empresa possua um ecossistema variado, este projeto focará especificamente no segmento de Empréstimos Pessoais e Concessão de Crédito.

Justificativa: A escolha desse recorte se deve à necessidade de entender como os modelos de Ciência de Dados do Nubank avaliam perfis de risco, com o objetivo de democratizar o acesso ao capital. É nesse contexto que o impacto da Inclusão Financeira (ODS 10) se torna mais claro, já que uma análise preditiva bem-feita permite que pessoas sem um histórico bancário tradicional tenham a chance de obter seu primeiro crédito.

2.3. Posicionamento no Mercado

O Nubank se firmou como a maior instituição financeira privada do Brasil em números de clientes. Em janeiro de 2026, a empresa anunciou que havia ultrapassado a marca de 112 milhões de clientes no país, o que equivale a cerca de 61% da população adulta brasileira. No final de 2025, o total global atingiu 131 milhões de clientes, contando Brasil, México e Colômbia. Além disso, a companhia foi reconhecida entre as instituições com a menor taxa de reclamação no ranking do Banco Central.

2.4. Número de Colaboradores

Para acompanhar seu crescimento, o Nubank revelou que o número de colaboradores aumentou em 26% entre setembro de 2023 e setembro de 2025, totalizando cerca de 9.500 funcionários. A empresa também anunciou investimentos para expandir seus escritórios no Brasil, visando apoiar essa nova fase de crescimento.

2.5. Iniciativas em Data Science

O Nubank se posiciona como uma empresa orientada por dados e tecnologia, com atuação forte em Data Science, Machine Learning e Business Analytics. Em seus canais técnicos, a empresa destaca que desenvolve modelos para melhorar a experiência do cliente, usando estatística, inteligência artificial e criatividade para prever comportamentos e apoiar decisões de negócio.



A empresa também publica conteúdos sobre experimentação em larga escala, incluindo o uso de CUPED em testes A/B com milhões de clientes e centenas de métricas, além de pesquisas e aplicações com foundation models e sistemas de IA em tempo real.

2.6. Trabalhos em destaque

Em inclusão financeira, o Nubank afirma ter sido responsável pela inclusão de 28 milhões de pessoas no sistema financeiro e por oferecer o primeiro cartão de crédito para mais de 29 milhões de pessoas. Esses números reforçam o papel da empresa na ampliação do acesso a serviços financeiros na América Latina.

Na área de risco e crédito, a empresa desenvolve modelos proprietários para avaliar clientes com pouco ou nenhum histórico bancário tradicional, apoiando a concessão de crédito de forma mais inclusiva e baseada em dados. Isso aparece também em seus materiais sobre expansão de crédito e uso de tecnologia própria.

3. Problema do Estudo

3.1. Definição do Problema e Questões de Pesquisa

O principal problema deste estudo reside na barreira de acesso ao crédito para perfis que não se enquadram nos critérios rígidos dos bancos tradicionais.

Perguntas que pretendemos responder com a AED:

- Quais variáveis socioeconômicas possuem maior correlação com a restrição ao crédito?
- Existe um padrão de valores para clientes com menor tempo de histórico de crédito?
- Como os valores discrepantes (outliers) e dados ausentes podem distorcer a percepção de risco de um cliente?



3.2. Abordagem pelo Pensamento Computacional

Para estruturar a solução analítica, o problema foi decomposto nos quatro pilares do pensamento computacional:

- **Decomposição:** O problema complexo da "Inclusão Financeira" foi dividido em subproblemas menores: análise do perfil demográfico, avaliação da estabilidade profissional e medição do comprometimento da renda.
- **Reconhecimento de Padrões:** Através da AED, buscaremos identificar comportamentos recorrentes em clientes adimplentes versus inadimplentes para entender o que define um "bom pagador" fora dos padrões convencionais.
- **Abstração:** Focaremos nas variáveis de maior impacto (como `person_income` e `loan_int_rate`), ignorando detalhes subjetivos que não contribuem para a previsão estatística de risco.
- **Algoritmos:** A solução final visa a base para um modelo preditivo que processe os metadados de forma automatizada, gerando uma pontuação de crédito mais justa e alinhada ao ODS 10.

4. Apresentação dos dados (Metadados)

O objetivo desta seção é caracterizar e registrar o conjunto de dados selecionado para garantir a rastreabilidade e a transparência da análise.

4.1. Registro do Dataset

- **Tipo de arquivo:** .csv (Comma Separated Values).
- **Origem dos dados:** Aberta (Plataforma Kaggle - *Credit Risk Dataset*).
- **Sensibilidade:** Baixa. O dataset é composto por perfis anonimizados, sem informações que permitam a identificação direta de indivíduos (como CPF ou nomes), atendendo aos princípios de privacidade.
- **Validade:** Coletado em março de 2026 para fins acadêmicos. Torna-se obsoleto ao final do componente curricular Projeto Aplicado I.
- **Fonte:** Kaggle; dataset disponibilizado publicamente.



- **Restrições de uso:** Uso acadêmico e educacional, respeitando as diretrizes da LGPD quanto ao tratamento de dados estatísticos.
- **Informações adicionais:** O dataset possui 32.581 registros e 12 colunas.

4.2. Dicionário de Dados

Com base na análise técnica realizada via biblioteca Pandas, os atributos foram mapeados conforme a tabela abaixo:

Variável	Descrição Técnica	Tipo de dado
person_age	Idade do solicitante (anos).	int64
person_income	Renda anual informada pelo cliente.	int64
person_home_ownership	Tipo de moradia (Aluguel, Própria, Hipoteca).	object
person_emp_length	Tempo de emprego em anos.	float64
loan_intent	Finalidade do empréstimo (Pessoal, Educação, etc).	object
loan_grade	Nota de risco atribuída ao empréstimo (A-G).	object
loan_amnt	Valor total do empréstimo solicitado.	int64
loan_int_rate	Taxa de juros anual aplicada.	float64
loan_status	Situação (0: Em dia, 1: Inadimplente).	int64
loan_percent_income	Relação entre o valor do empréstimo e a renda.	float64
cb_person_default_on_file	Histórico prévio de inadimplência (Y/N).	object
cb_person_cred_hist_length	Tempo de histórico de crédito (anos).	int64

5. Análise Exploratória de Dados (AED)

O objetivo desta etapa é aplicar a estatística descritiva para sumarizar as características do dataset, identificando padrões de comportamento e garantindo a integridade dos dados para as futuras modelagens de risco de crédito.

5.1. Visão Geral e Estatística Descritiva

Iniciamos a exploração calculando as medidas de posição (tendência central) e dispersão. O conjunto de dados conta com 32.581 registros e 12 colunas.

	person_age	person_income	person_emp_length	loan_amnt \
count	32581.000000	3.258100e+04	31686.000000	32581.000000
mean	27.734600	6.607485e+04	4.789686	9589.371106
std	6.348078	6.198312e+04	4.142630	6322.086646
min	20.000000	4.000000e+03	0.000000	500.000000
25%	23.000000	3.850000e+04	2.000000	5000.000000
50%	26.000000	5.500000e+04	4.000000	8000.000000
75%	30.000000	7.920000e+04	7.000000	12200.000000
max	144.000000	6.000000e+06	123.000000	35000.000000

	loan_int_rate	loan_status	loan_percent_income \
count	29465.000000	32581.000000	32581.000000
mean	11.011695	0.218164	0.170203
std	3.240459	0.413006	0.106782
min	5.420000	0.000000	0.000000
25%	7.900000	0.000000	0.090000
50%	10.990000	0.000000	0.150000
75%	13.470000	0.000000	0.230000
max	23.220000	1.000000	0.830000

	cb_person_cred_hist_length
count	32581.000000
mean	5.804211
std	4.055001
min	2.000000
25%	3.000000
50%	4.000000
75%	8.000000
max	30.000000

Figura 1 – Sumário estatístico das variáveis numéricas.

Análise dos Resultados:

- **Perfil Etário:** Na amostra analisada, a média de idade dos solicitantes é de 27,7 anos, com 75% da base tendo até 30 anos, o que reforça o posicionamento do Nubank entre o público jovem.
- **Renda e Crédito:** A renda média anual é de \$66.074, enquanto o ticket médio dos empréstimos solicitados é de \$9.589.

- **Dispersão:** Observamos um desvio padrão muito elevado na renda (\$61.983), indicando uma base heterogênea que abrange desde microempreendedores até perfis de alta renda.

5.2. Distribuição de Frequência (Valor de Empréstimo)

Para entender o volume das operações, analisamos a distribuição da variável `loan_amnt`.




Figura 2 – Histograma da distribuição do valor de empréstimo.

Interpretação:

O histograma revela uma concentração massiva de pedidos na faixa entre \$5.000 e \$10.000. A frequência cai drasticamente conforme o valor aumenta, o que demonstra o foco da instituição em democratizar o acesso ao crédito através de valores menores e mais pulverizados.



5.3. Análise de Correlações (Pearson)

Testamos a hipótese de que a renda ou o tempo de histórico seriam os únicos determinantes para a taxa de juros. Os resultados desafiam a lógica bancária tradicional.

- **Renda Pessoal vs. Taxa de Juros**

Calculamos o Coeficiente de correlação de Pearson para verificar se quem ganha mais paga menos juros.

```
# --- ANÁLISE DE CORRELAÇÃO: RENDA PESSOAL vs. TAXA DE JUROS ---
# O coeficiente varia de -1 a 1 e indica a força da relação linear entre Renda e Juros:

# 1. Próximo de -1 (Correlação Negativa Forte):
# Indica que quanto maior a renda, menores tendem a ser os juros.

# 2. Próximo de 0 (Correlação Linear Fraca ou Ausente):
# Indica que não há uma relação linear relevante entre as variáveis.
# Nesse caso, a renda isoladamente não influencia significativamente a taxa de juros

# 3. Próximo de 1 (Correlação Positiva Forte):
# Indica que quanto maior a renda, maiores tendem a ser os juros.

correlacao_renda_pessoal = df['person_income'].corr(df['loan_int_rate'])

print(f"O Coeficiente de Correlação é: {correlacao_renda_pessoal:.4f}")
✓ 0.0s

O Coeficiente de Correlação de Pearson é: 0.0008
```

Figura 3 – Cálculo da correlação de Pearson: Renda vs Juros.




Figura 4 – Gráfico de tendência: Renda vs. Juros.

O valor obtido indica uma ausência de correlação linear. Visualmente, a linha de tendência é horizontal, indicando que a renda pessoal não influencia significativamente na taxa de juros, permitindo que perfis de menor renda também acessem taxas competitivas.

- **Histórico de Crédito vs. Taxa de Juros**

Analizamos se o histórico de crédito no sistema financeiro dita o preço do crédito.

```
# --- ANÁLISE DE CORRELAÇÃO: HISTÓRICO DE CRÉDITO vs. TAXA DE JUROS ---
# O Coeficiente de Pearson avalia a relação linear entre o histórico de crédito e a taxa de juros:

# 1. Próximo de -1:
# Indica que quanto maior o histórico, menor tende a ser a taxa de juros.

# 2. Próximo de 0:
# Indica ausência de relação linear relevante entre as variáveis.
# Nesse caso, o histórico de crédito isoladamente não parece influenciar bem a taxa de juros.

# 3. Próximo de 1:
# Indica que quanto maior o histórico, maior tende a ser a taxa de juros.

# RESULTADO OBTIDO: 0.0167 (Praticamente zero)
# CONCLUSÃO: O tempo de histórico de crédito (cb_person_cred_hist_length) não apresenta
# relação linear relevante com a taxa de juros (loan_int_rate) neste dataset.

correlacao_tempo_credito = df['cb_person_cred_hist_length'].corr(df['loan_int_rate'])

print(f"O Coeficiente de Correlação é: {correlacao_tempo_credito:.4f}")
✓ 0.0s

O Coeficiente de Correlação é: 0.0167
```

Figura 5 – Cálculo da correlação de Pearson: Histórico vs. Juros.




Figura 6 – Gráfico de tendência: Histórico vs. Juros.



O resultado aponta que o histórico de crédito não influencia significativamente na taxa de juros. Isso é um forte indício de Inclusão Financeira (ODS 10), pois a correlação sugere que novos entrantes no mercado não são penalizados com taxas maiores apenas por serem "novos" no sistema.

5.4. Identificação de Anomalias e Outliers

A análise dos dados revelou pontos que precisam de atenção técnica antes de qualquer tomada de decisão:

- **Idade Impossível:** Detectamos um valor máximo de 144 anos na variável `person_age`.
- **Tempo de Emprego:** Foi registrado um máximo de 123 anos de tempo de serviço.
- **Renda Discrepante:** Um registro de renda de \$6 milhões que, embora possível, distorce as médias gerais e atua como um outlier no modelo.



6. Esboço do Storytelling para a Gravação do Vídeo Final

Este tópico apresenta o planejamento narrativo estruturado que guiará a futura apresentação em vídeo do projeto. O objetivo deste esboço é conectar os achados estatísticos da Análise Exploratória de Dados (AED) às diretrizes sociais e inclusivas propostas pela pesquisa.

1. Apresentação do Grupo e Integrantes: O vídeo será iniciado com a introdução do integrante Marcos Costa Lima Araujo (RA: 10746213), representando o Grupo 2A 6 do componente curricular de Projeto Aplicado I do curso de Tecnologia em Banco de Dados da Universidade Presbiteriana Mackenzie.

2. Nome do Projeto: "Análise de Impacto Social e Inclusão Financeira: Estudo de Caso Nubank".

3. Empresa/Organização de Estudo: O objeto de estudo selecionado é o Nubank, uma das maiores plataformas digitais de serviços financeiros do mundo, escolhido por sua atuação pioneira como fintech orientada a dados e uso intensivo de Data Science, Machine Learning e Big Data para otimizar a experiência do usuário.

4. Área do Problema: O projeto está delimitado na área de gerenciamento de risco de crédito e análise estatística voltada para o segmento de Empréstimos Pessoais e Concessão de Crédito.

5. Descrição do Problema / Gap: Os modelos tradicionais de aprovação de crédito baseiam-se em históricos bancários de longo prazo e réguas patrimoniais rígidas. Esse cenário gera um gap excludente que marginaliza cidadãos que não possuem relacionamento financeiro prévio consolidado, impedindo a bancarização e o acesso inicial a capital.

6. Proposta Analítica: Demonstrar, por meio dos pilares do Pensamento Computacional (Abstração e Reconhecimento de Padrões) e da aplicação de estatística descritiva, como modelos preditivos inteligentes e multifatoriais podem neutralizar critérios rígidos de elegibilidade, tornando as avaliações de



risco mais justas, transparentes e alinhadas ao propósito do ODS 10 (Redução das Desigualdades da ONU).

7. Dados Disponíveis: Utilização do conjunto de dados público Credit Risk Dataset (adquirido na plataforma Kaggle), composto por 32.581 registros e 12 variáveis socioeconômicas e financeiras estruturadas em formato .csv. Os dados são anonimizados e de baixa sensibilidade, operando em estrita conformidade com os princípios de privacidade determinados pela LGPD.

8. Análise Exploratória (AED): Apresentação dos principais achados da AED. Destacaremos o foco em microcrédito (empréstimos concentrados entre \$5.000 e \$10.000) e as correlações de Pearson próximas a zero (Renda: 0.0008; Histórico: 0.0167), que provam que o algoritmo avalia o comportamento individual e não pune o cliente por ter menor renda ou histórico recente. Também indicaremos a identificação de outliers como a idade anômala de 144 anos.

9. Resultados Pretendidos: Fornecer sustentação analítica que comprove o papel estratégico da Ciência de Dados na promoção da inclusão financeira e equidade social. O intuito final do estudo é evidenciar como o tratamento adequado de metadados apoia a construção de scores de crédito seguros e livres de vieses discriminatórios automatizados, impulsionando as metas de desenvolvimento sustentável de redução da desigualdade.