



UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO I – TECNOLOGIA EM BANCO DADOS

ANÁLISE DE IMPACTO SOCIAL E INCLUSÃO FINANCEIRA: ESTUDO DE CASO NUBANK

Nome da Empresa: Nubank

Número do Grupo: 2A 6

Integrantes: Marcos Costa Lima Araujo – RA: 10746213

Link do GitHub: <https://github.com/marcosaraujoCL/projeto-aplicado-inclusao-financeira>

SÃO PAULO – SP

2026



Sumário

1. Objetivo do Estudo	6
1.1. Objetivo Geral	6
1.2. Objetivos Específicos	6
2. Apresentação da Empresa Nubank	7
2.1. Missão, Visão e Valores	7
2.2. Segmento de Atuação	7
2.3. Posicionamento no Mercado	8
2.4. Número de Colaboradores	8
2.5. Iniciativas em Data Science	9
2.6. Trabalhos em Destaque	9
3. Problema do Estudo	10
3.1. Definição do Problema e Questões de Pesquisa	10
3.2. Abordagem pelo Pensamento Computacional	10
4. Apresentação dos Dados (Metadados)	11
4.1. Registro do Dataset	11
4.2. Dicionário de Dados	11
5. Análise Exploratória de Dados (AED)	12
5.1. Visão Geral e Estatística Descritiva	12
5.2. Distribuição de Frequência (Valor de Empréstimo)	13
5.3. Análise de Correlações (Pearson)	14
5.4. Identificação de Anomalias e Outliers	18
6. Esboço do Storytelling para a Gravação do Vídeo Final	19



Glossário

- **AED (Análise Exploratória de Dados):** Método de análise de conjuntos de dados para resumir suas características principais, frequentemente com recursos visuais.
- **Coeficiente de Correlação de Pearson:** Medida estatística (entre -1 e 1) que indica a força da relação linear entre duas variáveis, como Renda e Juros.
- **Dataset:** Conjunto de dados estruturado, no caso deste projeto, o arquivo `credit_risk_dataset.csv` com 32.581 registros.
- **Fintech:** Empresa de tecnologia que oferece serviços financeiros de forma digital, exemplificada pelo Nubank neste estudo.
- **LGPD:** Lei Geral de Proteção de Dados, que regula o tratamento de informações pessoais para garantir a privacidade.
- **Metadados:** Informações que descrevem as propriedades técnicas de um Dataset, como tipo de arquivo, origem e descrição dos atributos.
- **ODS 10:** Objetivo de Desenvolvimento Sustentável da ONU focado na Redução das Desigualdades, tema central deste projeto aplicado.
- **Outliers:** Valores atípicos ou anomalias encontradas nos dados, como a idade de 144 anos detectada na variável `person_age`.
- **Big Data:** Conjunto de técnicas e ferramentas capazes de processar, armazenar e analisar volumes massivos de dados estruturados e não estruturados em alta velocidade.
- **Machine Learning:** Subcampo da inteligência artificial focado no desenvolvimento de algoritmos que aprendem padrões a partir de dados históricos para realizar previsões ou tomar decisões de forma automatizada.
- **Storytelling:** Prática de contar histórias utilizando uma estrutura narrativa bem definida, dividida em setup, conflito e resolução, para transmitir uma mensagem ou apresentar um projeto de forma clara e envolvente.



Lista de Figuras

Figura 1 – Sumário estatístico das variáveis numéricas	12
Figura 2 – Histograma da distribuição do valor de empréstimo	13
Figura 3 – Gráfico de barras da distribuição do valor de empréstimo	14
Figura 4 – Cálculo de Pearson: Histórico anterior vs Situação atual	15
Figura 5 – Gráfico de barras: Histórico vs Situação atual	15
Figura 6 – Cálculo de Pearson: Renda vs Juros	16
Figura 7 – Gráfico de tendência: Renda vs Juros	17
Figura 8 – Cálculo de Pearson: Histórico vs Juros	17
Figura 9 – Gráfico de tendência: Histórico vs Juros	18



Lista de Tabelas

Tabela 1 – Dicionário de Dados e Metadados dos Atributos	11
--	----



1. Objetivo do Estudo

1.1. Objetivo Geral

O principal objetivo deste projeto é provar que as ferramentas da Ciência de Dados podem ajudar a examinar a situação da inclusão financeira de uma instituição financeira, com o Nubank como nosso estudo de caso. Queremos entender de que maneira modelos analíticos podem ajudar na precificação justa e a democratizar o acesso ao crédito para grupos que historicamente foram excluídos, contribuindo assim para o cumprimento do ODS 10 (Redução das Desigualdades da ONU).

1.2. Objetivos Específicos

Foram definidos os seguintes passos técnicos para esta etapa do projeto:

- **Contextualização Institucional:** Realizar uma análise do Nubank, identificando sua missão, visão, valores e posicionamento estratégico no mercado de tecnologia financeira.
- **Definição do problema:** definir o problema e perguntas que vão ser respondidas com a análise exploratória do dataset.
- **Registro de Metadados:** Caracterizar o dataset de Risco de Crédito, registrando sua origem, tipo de arquivo, descrição de atributos e conformidade com a LGPD.
- **Aplicação de Estatística Descritiva:** Calcular medidas de posição (média, moda, mediana) e dispersão (variância, desvio padrão) para as variáveis socioeconômicas e financeiras do conjunto de dados.
- **Identificação de Anomalias:** Detectar e analisar outliers (como inconsistências de idade) e valores perdidos que possam impactar a precisão dos modelos preditivos.
- **Fundamentação Computacional:** Aplicar os pilares da decomposição, reconhecimento de padrões e abstração para estruturar uma solução analítica viável ao problema de pesquisa.



2. Apresentação da Empresa Nubank

2.1. Missão, Visão e Valores

O Nubank tem como missão combater a complexidade e empoderar seus clientes, simplificando sua vida financeira com experiências justas e transparentes.

Sua visão é revolucionar o segmento financeiro na América Latina, tornando-se a instituição mais focada no cliente e inovadora do mundo, eliminando a burocracia.

Os valores do Nubank são compostos por cinco pilares, conhecidos como "Nu-values". São eles:

- **Queremos que nossos clientes nos amem fanaticamente:** Foco total no cliente.
- **Somos ávidos e desafiamos o status quo:** Questionar o sistema tradicional e promover mudanças.
- **Agimos como donos:** Senso de responsabilidade e propriedade.
- **Construímos equipes fortes e diversas:** Valorização de perspectivas diferentes.
- **Buscamos eficiência inteligente:** Soluções pioneiras e produtividade.

2.2. Segmento de Atuação

O Nubank é uma empresa de tecnologia com foco em serviços financeiros (fintech) que atua em diversas frentes no mercado brasileiro e internacional:

- **Cartões de Crédito:** Seu produto principal e porta de entrada para milhões de clientes.
- **Conta Digital:** Serviços de conta corrente e pagamentos.
- **Investimentos:** Plataforma de corretagem e fundos.
- **Seguros:** Proteção de vida, celular e automóveis.
- **Marketplace:** Shopping dentro do aplicativo.



Embora a empresa possua um ecossistema variado, este projeto focará especificamente no segmento de Empréstimos Pessoais e Concessão de Crédito.

Justificativa: A escolha desse recorte se deve à necessidade de entender como os modelos de Ciência de Dados do Nubank avaliam perfis de risco, com o objetivo de democratizar o acesso ao capital de maneira justa. É nesse contexto que o impacto da Inclusão Financeira (ODS 10) se torna mais claro, já que uma análise preditiva bem-feita, fundamentada em critérios multifatoriais, permite superar as barreiras impostas pelas réguas rígidas do mercado tradicional. Dessa forma, abre-se espaço para que pessoas sem um histórico bancário convencional ou de longo prazo tenham a oportunidade real de obter seu primeiro crédito de forma digna e equitativa.

2.3. Posicionamento no Mercado

O Nubank se firmou como a maior instituição financeira privada do Brasil em números de clientes. Em janeiro de 2026, a empresa anunciou que havia ultrapassado a marca de 112 milhões de clientes no país, o que equivale a cerca de 61% da população adulta brasileira. No final de 2025, o total global atingiu 131 milhões de clientes, contando Brasil, México e Colômbia. Além disso, a companhia foi reconhecida entre as instituições com a menor taxa de reclamação no ranking do Banco Central.

2.4. Número de Colaboradores

Para acompanhar seu crescimento, o Nubank revelou que o número de colaboradores aumentou em 26% entre setembro de 2023 e setembro de 2025, totalizando cerca de 9.500 funcionários. A empresa também anunciou investimentos para expandir seus escritórios no Brasil, visando apoiar essa nova fase de crescimento.



2.5. Iniciativas em Data Science

O Nubank se posiciona como uma empresa orientada por dados e tecnologia, com atuação forte em Data Science, Machine Learning e Business Analytics. Em seus canais técnicos, a empresa destaca que desenvolve modelos para melhorar a experiência do cliente, usando estatística, inteligência artificial e criatividade para prever comportamentos e apoiar decisões de negócio.

A empresa também publica conteúdos sobre experimentação em larga escala, incluindo o uso de CUPED em testes A/B com milhões de clientes e centenas de métricas, além de pesquisas e aplicações com foundation models e sistemas de IA em tempo real.

2.6. Trabalhos em destaque

No pilar da inclusão financeira, o Nubank destaca-se ao afirmar que foi o agente responsável pela introdução de 28 milhões de pessoas no sistema bancário, além de ter viabilizado o primeiro cartão de crédito para mais de 29 milhões de indivíduos. Esses indicadores empíricos expressivos consolidam o papel fundamental da instituição na ampliação do acesso a serviços financeiros e na democratização do capital em toda a América Latina.

Paralelamente, na área de gestão de risco e concessão de crédito, a empresa desenvolve e implementa modelos preditivos proprietários especificamente desenhados para avaliar proponentes com pouco ou nenhum histórico bancário tradicional. Essa abordagem analítica robusta mitiga as barreiras de entrada convencionais e apoia o fornecimento de recursos de forma significativamente mais inclusiva, justa e estritamente fundamentada em ciência de dados. Tais diretrizes operacionais são amplamente reforçadas em seus materiais institucionais informativos sobre a expansão do crédito e o uso de tecnologia corporativa própria.



3. Problema do Estudo

3.1. Definição do Problema e Questões de Pesquisa

O principal desafio deste estudo centra-se no risco de crédito e na precificação justa para perfis vulneráveis ou novos no sistema, historicamente excluídos por taxas de juros punitivas associadas à baixa renda ou curto histórico. A pesquisa também investiga como a inadimplência prévia estigmatiza o cliente e dificulta sua reintegração, além de avaliar como o tratamento técnico de *outliers* corrige distorções na percepção do risco. O objetivo é comprovar, via Análise Exploratória de Dados (AED), se os modelos analíticos e a Ciência de Dados atuam como ferramentas éticas e equitativas na concessão de crédito, alinhando-se às metas de redução de desigualdades da ODS 10 da ONU.

3.2. Abordagem pelo Pensamento Computacional

Para estruturar a solução analítica, o problema foi decomposto nos quatro pilares do pensamento computacional:

- **Decomposição:** O problema complexo da "Inclusão Financeira" foi dividido em subproblemas menores: análise do perfil demográfico, avaliação da estabilidade profissional e medição do comprometimento da renda.
- **Reconhecimento de Padrões:** Através da AED, buscaremos identificar comportamentos recorrentes em clientes adimplentes versus inadimplentes para entender o que define um "bom pagador" fora dos padrões convencionais.
- **Abstração:** Focaremos nas variáveis de maior impacto, ignorando detalhes subjetivos que não contribuem para a previsão estatística de risco.
- **Algoritmos:** A solução final visa a base para um modelo preditivo que processe os metadados de forma automatizada, gerando uma pontuação de crédito mais justa e alinhada ao ODS 10.



4. Apresentação dos dados (Metadados)

O objetivo desta seção é caracterizar e registrar o conjunto de dados selecionado para garantir a rastreabilidade e a transparência da análise.

4.1. Registro do Dataset

- **Tipo de arquivo:** .csv (Comma Separated Values).
- **Origem dos dados:** Aberta (Plataforma Kaggle - *Credit Risk Dataset*).
- **Sensibilidade:** Baixa. O dataset é composto por perfis anonimizados, sem informações que permitam a identificação direta de indivíduos (como CPF ou nomes), atendendo aos princípios de privacidade.
- **Validade:** Coletado em março de 2026 para fins acadêmicos. Torna-se obsoleto ao final do componente curricular Projeto Aplicado I.
- **Fonte:** Kaggle; dataset disponibilizado publicamente.
- **Restrições de uso:** Uso acadêmico e educacional, respeitando as diretrizes da LGPD quanto ao tratamento de dados estatísticos.
- **Informações adicionais:** O dataset possui 32.581 registros e 12 colunas.

4.2. Dicionário de Dados

Com base na análise técnica realizada via biblioteca Pandas e utilizando o pacote Preview, os atributos foram mapeados conforme a tabela abaixo:

Tabela 1 - Dicionário de Dados e Metadados dos Atributos.

Variável	Descrição Técnica	Tipo de dado
person_age	Idade do solicitante (anos).	int64
person_income	Renda anual informada pelo cliente.	int64
person_home_ownership	Tipo de moradia (Aluguel, Própria, Hipoteca).	object
person_emp_length	Tempo de emprego em anos.	float64
loan_intent	Finalidade do empréstimo (Pessoal, Educação, etc).	object
loan_grade	Nota de risco atribuída ao empréstimo (A-G).	object
loan_amnt	Valor total do empréstimo solicitado.	int64
loan_int_rate	Taxa de juros anual aplicada.	float64
loan_status	Situação (0: Em dia, 1: Inadimplente).	int64
loan_percent_income	Relação entre o valor do empréstimo e a renda.	float64
cb_person_default_on_file	Histórico prévio de inadimplência (Y/N).	object
cb_person_cred_hist_length	Tempo de histórico de crédito (anos).	int64

Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).



5. Análise Exploratória de Dados (AED)

O objetivo desta etapa é aplicar a estatística descritiva para sumarizar as características do dataset, identificando padrões de comportamento e garantindo a integridade dos dados para as futuras modelagens de risco de crédito.

5.1. Visão Geral e Estatística Descritiva

Iniciamos a exploração calculando as medidas de posição (tendência central) e dispersão. O conjunto de dados conta com 32.581 registros e 12 colunas.

Figura 1 - Sumário estatístico das variáveis numéricas.

	person_age	person_income	person_emp_length	loan_amnt	\
count	32581.000000	3.258100e+04	31686.000000	32581.000000	
mean	27.734600	6.607485e+04	4.789686	9589.371106	
std	6.348078	6.198312e+04	4.142630	6322.086646	
min	20.000000	4.000000e+03	0.000000	500.000000	
25%	23.000000	3.850000e+04	2.000000	5000.000000	
50%	26.000000	5.500000e+04	4.000000	8000.000000	
75%	30.000000	7.920000e+04	7.000000	12200.000000	
max	144.000000	6.000000e+06	123.000000	35000.000000	
	loan_int_rate	loan_status	loan_percent_income	\	
count	29465.000000	32581.000000	32581.000000		
mean	11.011695	0.218164	0.170203		
std	3.240459	0.413006	0.106782		
min	5.420000	0.000000	0.000000		
25%	7.900000	0.000000	0.090000		
50%	10.990000	0.000000	0.150000		
75%	13.470000	0.000000	0.230000		
max	23.220000	1.000000	0.830000		
	cb_person_cred_hist_length				
count	32581.000000				
mean	5.804211				
std	4.055001				
min	2.000000				
25%	3.000000				
50%	4.000000				
75%	8.000000				
max	30.000000				

Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).


Análise dos Resultados:

- **Perfil Etário:** Na amostra analisada, a média de idade dos solicitantes é de 27,7 anos, com 75% da base tendo até 30 anos, o que reforça o posicionamento do Nubank entre o público jovem.
- **Renda e Crédito:** A renda média anual é de \$66.074, enquanto o ticket médio dos empréstimos solicitados é de \$9.589.
- **Dispersão:** Observamos um desvio padrão muito elevado na renda (\$61.983), indicando uma base heterogênea que abrange desde microempreendedores até perfis de alta renda.

5.2. Distribuição de Frequência (Valor de Empréstimo)


Para compreender a volumetria das operações de crédito da instituição, avaliou-se a variável `loan_amnt` sob duas perspectivas complementares: a distribuição contínua de frequências absolutas e a segmentação categórica por faixas comerciais em valores percentuais.

Figura 2 - Histograma da distribuição do valor de empréstimo.



Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Figura 3 - Gráfico de barras da distribuição do valor de empréstimo.



Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Interpretação:

O histograma revela que a concessão de crédito possui uma distribuição concentrada em quantias menores, acumulando a massa principal de pedidos no início do gráfico. Essa evidência é consolidada na análise percentual por faixas, que comprova que mais de 66% de toda a base de clientes acessa créditos de até \$10.000 (sendo 29,1% até \$5.000 e 37,0% entre \$5.000 e \$10.000). Esse padrão estatístico demonstra, na prática e através de dados reais, o alinhamento da instituição com o conceito de microcrédito e a democratização do acesso ao capital (ODS 10), priorizando a pulverização de recursos em detrimento da concentração de grandes montantes.

5.3. Análise de Correlações (Pearson)

Nesta etapa, realizamos análises estruturadas de correlação de Pearson e geramos gráficos de tendência para avaliar se existe ou não uma relação linear relevante entre as variáveis selecionadas. Esse processo metodológico serve para investigar detalhadamente o comportamento dos atributos socioeconômicos e testar de forma empírica as hipóteses levantadas frente aos paradigmas do mercado financeiro tradicional.

- **Histórico prévio de inadimplência vs Situação atual**

Calculamos o coeficiente de correlação Pearson para verificar se existe correlação entre essas duas variáveis e geramos um gráfico para um entendimento visual.

Figura 4 - Cálculo de Pearson: Histórico anterior vs Situação atual.

```
# --- ANÁLISE DE CORRELAÇÃO: Situação atual (Loan status) vs. Problema financeiros anteriores (cb_person_default_on_file) ---
# O coeficiente varia de -1 a 1 e indica a força da relação linear entre Situação atual e Problema financeiros anteriores:

# 1. Próximo de -1 (Correlação Negativa Forte):
# Indica que possivelmente quanto mais problemas financeiros anteriores (cb_person_default_on_file = 'Y'),
# menor a probabilidade de um status de empréstimo positivo.

# 2. Próximo de 0 (Correlação Linear Fraca ou Ausente):
# Indica que possivelmente não há uma relação linear relevante entre as variáveis.
# Nesse caso, os problemas financeiros anteriores não influenciam significativamente o status do empréstimo.


# 3. Próximo de 1 (Correlação Positiva Forte):
# Indica que possivelmente quanto mais problemas financeiros anteriores (cb_person_default_on_file = 'Y'),
# maior a probabilidade de um status de empréstimo negativo.

df['cb_person_default_on_file_num'] = df['cb_person_default_on_file'].map({'Y':1,'N':0})
correlação_situação_vs_problemas = df['loan_status'].corr(df['cb_person_default_on_file_num'])
print(f"O Coeficiente de Correlação é: {correlação_situação_vs_problemas:.4f}")

O Coeficiente de Correlação é: 0.1791
```

Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Figura 5 - Gráfico de barras: Histórico vs Situação atual.



Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).



Interpretação:

A análise revelou um Coeficiente de Pearson de 0,1791 entre o histórico anterior e a situação atual do contrato, indicando uma relação linear positiva fraca. Na prática, isso desmistifica o passado como fator determinante de risco: enquanto a maioria dos clientes com default anterior (3.573 pessoas) mantém suas contas em dia, um grupo expressivo com histórico limpo (4.936 pessoas) está inadimplente no contrato vigente. Portanto, os números provam que o modelo avalia o risco com base no comportamento real e no mérito do cliente dentro do contrato ativo. A inadimplência deixa de ser uma exclusão automática e passa a refletir ações presentes, garantindo uma reintegração financeira ética alinhada à ODS 10.

- **Renda Pessoal vs Taxa de Juros**

Para analisar a relação entre renda anual e taxa de juros, calculou-se o Coeficiente de Pearson. Na sequência, gerou-se um gráfico de tendência limitando a visualização a rendas de até 400.000, intervalo que concentra a maior parte da amostra do dataset.

Figura 6 - Cálculo de Pearson: Renda vs Juros.

```
# --- ANÁLISE DE CORRELAÇÃO: RENDA PESSOAL vs. TAXA DE JUROS ---
# O coeficiente varia de -1 a 1 e indica a força da relação linear entre Renda e Juros:

# 1. Próximo de -1 (Correlação Negativa Forte):
# Indica que quanto maior a renda, menores tendem a ser os juros.

# 2. Próximo de 0 (Correlação Linear Fraca ou Ausente):
# Indica que não há uma relação linear relevante entre as variáveis.
# Nesse caso, a renda isoladamente não influencia significativamente a taxa de juros

# 3. Próximo de 1 (Correlação Positiva Forte):
# Indica que quanto maior a renda, maiores tendem a ser os juros.


correlacao_renda_pessoal = df['person_income'].corr(df['loan_int_rate'])

print(f"O Coeficiente de Correlação é: {correlacao_renda_pessoal:.4f}")
✓ 0.0s

O Coeficiente de Correlação de Pearson é: 0.0008
```

Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Figura 7 - Gráfico de tendência: Renda vs Juros.



Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Interpretação:

O resultado indica ausência de correlação. A linha de tendência horizontal demonstra que a renda pessoal não influencia significativamente a taxa de juros, permitindo que perfis de menor renda acessem taxas competitivas.

- **Histórico de Crédito vs Taxa de Juros**

Analisamos se o histórico de crédito no sistema financeiro dita os juros.

Figura 8 - Cálculo de Pearson: Histórico vs Juros.

```
# --- ANÁLISE DE CORRELAÇÃO: HISTÓRICO DE CRÉDITO VS. TAXA DE JUROS ---
# O Coeficiente de Pearson avalia a relação linear entre o histórico de crédito e a taxa de juros:

# 1. Próximo de -1:
# Indica que quanto maior o histórico, menor tende a ser a taxa de juros.

# 2. Próximo de 0:
# Indica ausência de relação linear relevante entre as variáveis.
# Nesse caso, o histórico de crédito isoladamente não parece influenciar bem a taxa de juros.

# 3. Próximo de 1:
# Indica que quanto maior o histórico, maior tende a ser a taxa de juros.


# RESULTADO OBTIDO: 0.0167 (Praticamente zero)
# CONCLUSÃO: O tempo de histórico de crédito (cb_person_cred_hist_length) não apresenta
# relação linear relevante com a taxa de juros (loan_int_rate) neste dataset.

correlacao_tempo_credito = df['cb_person_cred_hist_length'].corr(df['loan_int_rate'])

print(f"O Coeficiente de Correlação é: {correlacao_tempo_credito:.4f}")
✓ 0.0s
O Coeficiente de Correlação é: 0.0167
```

Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Figura 9 - Gráfico de tendência: Histórico vs Juros.



Fonte: Elaborado pelo autor (2026), com base em Kaggle (2026).

Interpretação:

O resultado sinaliza uma tendência de que o histórico de crédito não seja um fator determinante na taxa de juros. Isso é um forte indício de Inclusão Financeira (ODS 10), pois a correlação sugere que novos entrantes no mercado não são penalizados com taxas maiores apenas por serem "novos" no sistema.

5.4. Identificação de Anomalias e Outliers

A análise dos dados revelou pontos que precisam de atenção técnica antes de qualquer tomada de decisão:

- **Idade Impossível:** Detectamos um valor máximo de 144 anos na variável `person_age`.
- **Tempo de Emprego:** Foi registrado um máximo de 123 anos de tempo de serviço.
- **Renda Discrepante:** Um registro de renda de \$6 milhões que, embora possível, distorce as médias gerais e atua como um outlier no modelo.



6. Esboço do Storytelling para a Gravação do Vídeo Final

Este tópico apresenta o planejamento narrativo estruturado que guiará a futura apresentação em vídeo do projeto. O objetivo deste esboço é conectar os achados estatísticos da Análise Exploratória de Dados (AED) às diretrizes sociais e inclusivas propostas pela pesquisa.

1. Apresentação do Grupo e Integrantes: O vídeo será iniciado com a introdução do integrante Marcos Costa Lima Araujo (RA: 10746213), representando o Grupo 2A 6 do componente curricular de Projeto Aplicado I do curso de Tecnologia em Banco de Dados da Universidade Presbiteriana Mackenzie.

2. Nome do Projeto: "Análise de Impacto Social e Inclusão Financeira: Estudo de Caso Nubank".

3. Empresa/Organização de Estudo: O objeto de estudo selecionado é o Nubank, uma das maiores plataformas digitais de serviços financeiros do mundo, escolhido por sua atuação pioneira como fintech orientada a dados e uso intensivo de Data Science, Machine Learning e Big Data para otimizar a experiência do usuário.

4. Área do Problema: O projeto está delimitado na área de gerenciamento de risco de crédito e análise estatística voltada para o segmento de Empréstimos Pessoais e Concessão de Crédito.

5. Descrição do Problema / Gap: O gargalo central do mercado tradicional reside no risco de crédito e na ausência de uma precificação justa para perfis vulneráveis ou novos entrantes no sistema financeiro. A exclusão manifesta-se por meio de taxas de juros abusivas e punitivas que penalizam indivíduos de menor renda ou com históricos curtos de relacionamento, além do estigma gerado por inadimplências passadas que dificultam a reintegração do cliente. Soma-se a isso a presença de anomalias (*outliers*) que distorcem a percepção analítica do risco, estabelecendo o desafio de demonstrar, via Análise Exploratória de Dados (AED), se modelos modernos e a Ciência de Dados



podem atuar como ferramentas éticas e eficazes para garantir um acesso ao crédito equitativo e alinhado à ODS 10 da ONU.

6. Proposta Analítica: Demonstrar, por meio dos pilares do Pensamento Computacional (Abstração e Reconhecimento de Padrões) e da aplicação de estatística descritiva, como modelos preditivos inteligentes e multifatoriais podem neutralizar critérios rígidos de elegibilidade, tornando as avaliações de risco mais justas, transparentes e alinhadas ao propósito do ODS 10 (Redução das Desigualdades da ONU).

7. Dados Disponíveis: Utilização do conjunto de dados público Credit Risk Dataset (adquirido na plataforma Kaggle), composto por 32.581 registros e 12 variáveis socioeconômicas e financeiras estruturadas em formato .csv. Os dados são anonimizados e de baixa sensibilidade, operando em estrita conformidade com os princípios de privacidade determinados pela LGPD.

8. Análise Exploratória (AED):

Apresentação prática e quantitativa dos três grandes pilares analíticos do projeto. Primeiro, destaca-se a volumetria de microcrédito, provando que 66,1% de toda a base acessa empréstimos de até \$10.000, o que confirma a pulverização democrática dos recursos. Segundo, demonstra-se que o Coeficiente de Pearson entre o histórico anterior e a inadimplência atual é de apenas 0,1791 (relação fraca), quebrando o estigma do passado: enquanto a maioria dos clientes com default anterior (**3.573 pessoas**) mantém suas contas em dia, um grupo expressivo com histórico limpo (**4.936 pessoas**) está inadimplente no contrato vigente, provando que o risco se baseia no comportamento real e no mérito. Terceiro, revelam-se as correlações lineares coladas no zero (0,0008 para renda anual e 0,0167 para tempo de histórico) com linhas de tendência horizontais, indicando matematicamente que a taxa de juros não discrimina ou pune perfis de baixa renda ou novos entrantes no mercado de trabalho. Por fim, detalha-se a higienização de dados e o tratamento de anomalias críticas (como idades de 144 anos) para garantir um modelo analítico ético e livre de vieses, consolidando o cumprimento da ODS 10.



9. Resultados Pretendidos: Fornecer sustentação analítica que comprove o papel estratégico da Ciência de Dados na promoção da inclusão financeira e equidade social. O intuito final do estudo é evidenciar como o tratamento adequado de metadados apoia a construção de scores de crédito seguros e livres de vieses discriminatórios automatizados, impulsionando as metas de desenvolvimento sustentável de redução da desigualdade.